

Agrupamento de dados em *Data Lakes* utilizando a meta-heurística BRKGA

Luis Henrique Vieira Viana¹², João Gabriel Marques de Lima¹², Tamer Stefani Guimaraes Cavalcante¹³, Rian Gabriel Santos Pinheiro², Danilo Fernandes¹, André Luiz Lins de Aquino¹²

¹Laboratório Orion

Centro de Inovação do Jaraguá, R. Melo Póvoas, 110 - Sala 109 - Jaraguá, Maceió - AL, 57022-230

²Universidade Federal de Alagoas (UFAL)

Av. Lourival Melo Mota, S/N - Tabuleiro do Martins, Maceió - AL, 57072-970

³Instituto Federal de Alagoas (IFAL)

R. Mizael Domingues, 530 - Centro, Maceió - AL, 57020-600

{luis.viana, joao.gabriel, tamer.cavalcante, dfc}@orion.ufal.br,
{rian, alla}@ic.ufal.br

RESUMO

Os *Data Lakes* vêm ganhando destaque na área de banco de dados graças à sua capacidade de armazenar grandes quantidades de dados de forma flexível e escalável. Tipicamente, métodos de agrupamento (*clustering*) são utilizados para explorar dados em *Data Lakes*, dada a sua natureza não supervisionada. Este trabalho propõe a aplicação do *Biased Random-Key Genetic Algorithm* (BRKGA) ao problema de agrupamento automático em *Data Lakes*. A abordagem foi avaliada em 17 *Data Lakes* e comparada ao algoritmo de referência RÓMULO. Foram analisadas a qualidade do agrupamento e a eficiência computacional. Na análise de qualidade, as métricas *Silhouette*, *Davies-Bouldin* e *Calinski-Harabasz* foram utilizadas para verificar a compacidade e separação dos agrupamentos obtidos. O BRKGA superou o RÓMULO em ambas as análises, apresentando valores consistentes nas métricas de avaliação e menor tempo de execução.

PALAVRAS CHAVE. *Data Lakes*, Agrupamento Automático, Algoritmos Genéticos.

Tópicos: AS&DS – Análise e Ciência de Dados, MH – Meta-heurísticas.

ABSTRACT

Data Lakes have been gaining prominence in the database field due to their ability to store large amounts of data in a flexible and scalable manner. Typically, clustering methods are used to explore data in *Data Lakes*, given their unsupervised nature. This work proposes the application of the *Biased Random-Key Genetic Algorithm* (BRKGA) to the automatic clustering problem in *Data Lakes*. The approach was evaluated on 17 *Data Lakes* and compared to the reference algorithm RÓMULO. Both clustering quality and computational efficiency were analyzed. For the quality analysis, the *Silhouette*, *Davies-Bouldin*, and *Calinski-Harabasz* metrics were used to verify the compactness and separation of the obtained clusters. BRKGA outperformed RÓMULO in both analyses, yielding consistent values across the evaluation metrics and a shorter execution time.

KEYWORDS. *Data Lakes*. Automatic Clustering. Genetic Algorithms.

Paper topics: AS&DS – Data Analysis and Data Science, MH – Metaheuristics.

1. Introdução

O grande volume de dados tornou-se um dos desafios mais relevantes na área de pesquisa em bancos de dados [Hai et al., 2023]. O grande volume, a variedade e a velocidade dos dados dificultam sua coleta, armazenamento e processamento de forma eficiente. A variedade de dados ainda representa um desafio significativo, com diversos problemas em aberto [Putrama e Martinek, 2024]. Com o aumento do volume de dados em aplicações específicas, a necessidade de extrair informações desses dados de forma desacoplada da aplicação à qual se destinam motivou a proposição do conceito de *Data Lake*. Essencialmente, um *Data Lake* é um sistema de armazenamento e gerenciamento de dados flexível e escalável, capaz de ingerir e armazenar dados brutos provenientes de fontes heterogêneas em seus formatos originais [Hai et al., 2023].

O agrupamento de dados (*clustering*) justifica-se como um dos modos primordiais de aprendizado, permitindo organizar objetos em grupos baseados em similaridades intrínsecas ou proximidade, especialmente na ausência de rótulos de classe prévios (aprendizado não supervisionado) [Rodriguez et al., 2019]. O objetivo principal é descobrir a estrutura natural e latente inerente aos dados, servindo como uma ferramenta exploratória para gerar hipóteses, detectar anomalias, identificar características salientes e reduzir a dimensionalidade de dados complexos [Rodriguez et al., 2019]. De maneira geral, essas técnicas organizam os dados em grupos, de modo que instâncias semelhantes sejam atribuídas ao mesmo grupo. Ao particionar os dados, busca-se otimizar a homogeneidade, minimizando a distância *intra-cluster* (entre membros do mesmo grupo) e maximizando a distância *inter-cluster* (entre grupos distintos). Além disso, o agrupamento atua como um mecanismo eficiente de compressão de dados, permitindo a sumarização de grandes volumes de informações através de protótipos de grupos, o que facilita o processamento e a interpretação.

Apesar de sua flexibilidade, explorar os dados armazenados em *Data Lakes* ainda é um desafio. A grande quantidade de informações distribuídas em diversas fontes torna complexa a identificação de sua origem e a compreensão de seus conteúdos. Além disso, por serem heterogêneos e, muitas vezes, não possuírem metadados suficientes para explicá-los, esses dados dificultam a interpretação adequada pelos usuários. Consequentemente, torna-se difícil compreender e utilizar os dados de maneira eficaz [Kachaoui e Belangour, 2019a,b].

Nesse contexto, abordagens que busquem explorar dados em *Data Lakes* através de técnicas de agrupamento devem considerar alguns desafios para garantir um agrupamento de qualidade: i) as técnicas devem ser capazes de lidar tanto com dados de baixa quanto de alta dimensionalidade, uma vez que os dados armazenados em *Data Lakes* podem ter diferentes dimensões; ii) o método deve incorporar mecanismos de determinação automática do número de grupos, pois não se pode esperar que o usuário conheça esse valor previamente; iii) as técnicas devem ser capazes de lidar com diferentes tipos de conjuntos de dados, sem a necessidade de reconfigurar manualmente seus parâmetros para cada novo conjunto.

Na literatura, há diversas abordagens que buscam solucionar os desafios mencionados. Entre elas, destacam-se métodos bioinspirados [Ikotun et al., 2021; Nanda e Panda, 2014], que utilizam meta-heurísticas como algoritmos genéticos para explorar soluções em um espaço de busca. Outros trabalhos [Alam et al., 2014; Rana et al., 2011] investigam abordagens baseadas em algoritmos de enxame de partículas. Recentemente, algumas propostas exploraram técnicas de *deep learning* [Karim et al., 2021; Min et al., 2018; Ren et al., 2024]. Além disso, existem ainda abordagens mais gerais aplicadas ao problema [Greenlaw e Kantabutra, 2013; Jain, 2010; Oyewole e Thopil, 2023].

Em 2022, Jiménez et al. [2022] propôs um algoritmo genético denominado RÓMULO, desenvolvido especificamente para o contexto de agrupamento automático em *Data Lakes*. Embora o método trate de forma eficiente diversos desafios encontrados na literatura, ele ainda enfrenta

limitações relacionadas ao seu tempo de processamento, tornando-o menos eficiente em cenários com dados de alta dimensionalidade.

Buscando superar limitações de métodos anteriores, este trabalho propõe a aplicação do *Biased Random-Key Genetic Algorithm* (BRKGA) [Gonçalves e Resende, 2011], um algoritmo genético de propósito geral para problemas de otimização, ao contexto de agrupamento em *Data Lakes*. O método proposto foi comparado com o RÓMULO. A avaliação dos resultados foi conduzida considerando dois aspectos principais. O primeiro diz respeito à capacidade do algoritmo em identificar grupos compactos e bem separados, avaliada por meio de um conjunto de 17 *Data Lakes* contendo dados reais. Para essa análise, foram empregadas métricas clássicas de avaliação de agrupamento: *Silhouette* [Rousseeuw, 1987], *Davies-Bouldin* [Davies e Bouldin, 1979] e *Calinski-Harabasz* [Caliński e Harabasz, 1974]. O segundo aspecto avaliado refere-se ao tempo de execução de ambos os algoritmos.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a formulação do problema; a Seção 3 descreve o método proposto; a Seção 4 apresenta os experimentos; por fim, a Seção 5 apresenta as conclusões do trabalho.

2. Formulação do Problema




Figura 1: Processo de agrupamento de dados.

Seja $X = \{x_1, x_2, \dots, x_n\}$, $X \in \mathbb{R}^{n \times m}$ um conjunto de dados composto por n objetos, em que cada objeto $x_i \in \mathbb{R}^m$ é descrito por m variáveis. O objetivo do agrupamento automático é particionar o conjunto de dados em um conjunto de grupos sem conhecimento prévio do número correto de grupos. Esse processo pode ser observado na Figura 1. Porém, quando o volume de dados é elevado, além de determinar a estrutura de agrupamento, também é desejável identificar o subconjunto de variáveis que melhor descreve essa estrutura, uma vez que variáveis irrelevantes ou redundantes podem impactar negativamente a qualidade do agrupamento.

Dessa forma, o problema de agrupamento automático consiste em determinar o melhor agrupamento sobre os dados projetados em um subconjunto de variáveis $S \subseteq 1, 2, \dots, m$, bem como a quantidade ideal de grupos k . Dada uma solução candidata definida pelo par (k, S) , o conjunto de dados é projetado sobre as variáveis selecionadas, resultando em um conjunto de dados reduzido $X_S \in \mathbb{R}^{n \times |S|}$. Em seguida, um algoritmo de agrupamento externo é aplicado a X_S com o objetivo de particionar os objetos em k grupos. A qualidade do resultado obtido é avaliada por meio de um coeficiente de agrupamento. Neste trabalho, foram utilizadas as métricas *Silhouette*, *Davies-Bouldin* e *Calinski-Harabasz*.

Assim, o objetivo do problema de agrupamento automático considerado neste trabalho é encontrar o par (k, S) que otimize o valor da métrica de agrupamento do resultado produzido

por um algoritmo de agrupamento externo a partir do conjunto de dados projetado nas variáveis selecionadas. Formalmente, o problema pode ser expresso como:

$$\begin{aligned} \max_{k,S} \quad & \text{métrica_agrupamento}(X_S, k) \\ \text{s.a.} \quad & 2 \leq k \leq k_{\max}, \quad k_{\max} = \frac{n}{2}, \\ & S \subseteq \{1, 2, \dots, m\}. \end{aligned} \quad (1)$$

O valor de $k_{\max}$ define o número máximo de grupos permitido no espaço de busca. Dessa forma, o processo de otimização busca identificar simultaneamente o número de grupos mais adequado e o subconjunto de variáveis que melhor evidencia a estrutura de agrupamento presente nos dados.

3. Método Proposto

O *Biased Random-Key Genetic Algorithm* (BRKGA), proposto por Gonçalves e Resende [2011], é um *framework* de propósito geral para otimização combinatória que se destaca pela clara separação entre seus componentes independentes e dependentes do problema. No *framework*, soluções são codificadas como vetores de chaves aleatórias no intervalo $[0, 1]$, e uma população desses vetores é evoluída ao longo de gerações.

O componente dependente do problema no BRKGA é o *Decoder*, um algoritmo determinístico que mapeia qualquer vetor de chaves aleatórias em uma solução viável do problema e calcula seu valor de aptidão (*fitness*). Toda a lógica evolutiva (cruzamento, mutação e seleção) é realizada no espaço contínuo das chaves, enquanto o *Decoder* faz a ponte com o espaço de soluções do problema de otimização. Isso permite que o mesmo código do *framework* seja reutilizado para diferentes problemas, bastando implementar um novo *Decoder*.

Uma versão do BRKGA para o problema de agrupamento automático foi proposta por [Lima et al., 2021]. No entanto, o *Decoder* proposto foi concebido para o problema de agrupamento clássico e não incorpora seleção de variáveis, o que é um requisito importante no contexto de *Data Lakes*, onde dados de alta dimensionalidade com variáveis irrelevantes ou redundantes podem comprometer a qualidade do agrupamento. Além disso, o trabalho considera apenas o índice Silhouette como função objetivo, o que limita a análise da qualidade dos agrupamentos obtidos. Considerando essas limitações, o *Decoder* proposto neste trabalho é apresentado no Algoritmo 1. A função recebe como entrada o conjunto de dados X a ser analisado, o parâmetro α e um indivíduo da população (cromossomo). O cromossomo possui tamanho $m + 2$, em que m corresponde ao número de variáveis do conjunto de dados X . O primeiro alelo representa o número de grupos k , enquanto o segundo alelo indica a porcentagem de variáveis de X que serão selecionadas para o agrupamento. Os demais alelos correspondem às m variáveis do conjunto X . A função retorna o valor de *fitness* associado ao indivíduo avaliado, com base na métrica de avaliação selecionada.

O procedimento é composto por três etapas sequenciais. Na primeira, o segundo alelo do cromossomo, $c_1 \in [0, 1]$, é utilizado para determinar a quantidade de variáveis a serem selecionadas, obtida por $\text{round}(c_1 \times n_{\text{vars}})$. Em seguida, os alelos $c_2, \dots, c_{n+1}$ são ordenados de forma crescente, formando um ranqueamento das variáveis. As primeiras variáveis desse ordenamento são mantidas e o conjunto de dados é filtrado, preservando apenas as selecionadas.

Na segunda etapa, determina-se o número de grupos k a partir do primeiro alelo $c_0 \in [0, 1]$. Define-se $k_{\max} = \lfloor \text{linhas distintas}(X_F)/2 \rfloor$ e aplica-se um mapeamento exponencial parametrizado por α , que introduz um viés favorecendo valores menores de k :

$$k = 2 + \left\lceil (k_{\max} - 2) \cdot \frac{e^{\alpha \cdot c_0} - 1}{e^{\alpha} - 1} \right\rceil$$

Algoritmo 1: Decoder

Entrada: Conjunto de dados X , Cromossomo $c = [c_0, c_1, c_2, \dots, c_{n+1}]$, parâmetro α

Saída : Valor de fitness f

Passo 1: Seleção de variáveis

O gene $c_1 \in [0, 1]$ determina a fração de variáveis a utilizar. Calcula-se

$$m = \text{round}(c_1 \times X.n_vars).$$

if $m < 2$ **then return** $f \leftarrow M$;

Os genes $c_2, \dots, c_{n+1}$ são usados para ranquear as variáveis de X . Seleccionam-se as m variáveis de menor valor associado, formando o subconjunto X_F .

if número de linhas distintas em $X_F < 2$ **then return** $f \leftarrow M$;

Passo 2: Determinação do número de grupos k

O limite superior é $k_{max} = \lfloor \text{linhas distintas}(X_F)/2 \rfloor$.

if $k_{max} < 2$ **then return** $f \leftarrow M$;

O gene $c_0 \in [0, 1]$ determina k via mapeamento exponencial controlado por α , favorecendo valores menores de k :

$$k \leftarrow 2 + \left\lfloor (k_{max} - 2) \cdot \frac{e^{\alpha \cdot c_0} - 1}{e^\alpha - 1} \right\rfloor$$

Passo 3: Agrupamento e cálculo do fitness

Aplica-se *K-Means* sobre X_F com k grupos.

if algum grupo ficar vazio **then return** $f \leftarrow M$;

Calcula-se a métrica de agrupamento sobre X_F e retorna-se $f \leftarrow$ pontuação da métrica.

Quanto maior o valor de α , maior o viés introduzido. Com base em experimentações, adotou-se neste trabalho o valor $\alpha = 1.5$.

Na terceira etapa, aplica-se o algoritmo K-MEANS sobre o conjunto filtrado X_F com k grupos. Para conjuntos com número elevado de instâncias (neste trabalho, foram considerados valores acima de 1000 instâncias), utiliza-se a variante MINIBATCH K-MEANS com o objetivo de reduzir o custo computacional. O resultado é avaliado por uma das três métricas: *Silhouette* (Sil), *Davies-Bouldin* (DB) ou *Calinski-Harabasz* (CH). Como o BRKGA é um algoritmo de minimização, métricas de maximização, como Sil e CH, devem retornar seu *score* negativo. Caso alguma etapa produza uma solução inválida, retorna-se uma constante de penalização $M = 10^6$.

4. Experimentos

Esta seção apresenta os detalhes da análise experimental realizada. Inicialmente, as configurações dos experimentos são descritas na Seção 4.1. Em seguida, a Seção 4.2 detalha o processo de configuração dos algoritmos utilizados. A metodologia empregada para a obtenção dos resultados é apresentada na Seção 4.3. Por fim, as Seções 4.4 e 4.5 apresentam, respectivamente, os resultados das análises de agrupamento e de tempo de execução.

4.1. Configurações dos experimentos

Os *Data Lakes* utilizados estão descritos na Tabela 1. Eles foram obtidos a partir do repositório disponibilizado em [Jiménez et al., 2022], embora representem apenas uma fração do conjunto original. Em média, cada *Data Lake* contém 5,94 conjuntos de dados, com um máximo global de 20 e um mínimo global de 1 conjunto. Cada conjunto possui, em média, 1.164,91 instâncias, variando entre um máximo global de 8.788 e um mínimo global de 4 instâncias. O número médio de atributos é de 189,78, com um máximo global de 861 e um mínimo global de 4 atributos.

Tabela 1: Descrição dos *Data Lakes*.

<i>Data Lake</i>	# Conjuntos de dados	Número de objetos			Número de atributos		
		Min.	Méd.	Max.	Min.	Méd.	Max.
Agrifood-Exports	11	6	27.90	53	10	33.63	63
Art-Funding	4	12	152.50	459	34	187.25	396
Brasilian-Taxes	1	8788	8788	8788	8	8	8
COVID	3	26	352.33	1004	34	105.66	215
Crimes	7	463	1041.71	2996	84	319.28	449
Divorces	17	24	354.76	1176	34	207.23	353
EU-Fruit-Data	1	205	205.00	205	861	861.00	861
Farm-Operators	10	792	1834.80	3564	36	58.30	101
Gas-Emissions	4	4	80.00	263	4	32.00	70
Hiking-Tours	1	1025	1025.00	1025	829	829.00	829
Marriage	4	17	17.00	17	22	74.50	100
Rockfall-Risk	20	362	1951.75	2627	27	33.90	35
Second-Language	3	9	101.33	153	32	36.33	42
Teen-Pregnancy	5	560	722.80	1094	35	42.40	52
Tuition-Fees	4	2494	3063.50	4200	44	54.50	59
UBER-Trips	1	59	59.00	59	324	324.00	324
WiFi-Hotspots	5	17	26.20	30	4	19.40	36

O código do BRKGA foi obtido a partir do repositório público disponibilizado pelos autores originais¹. Embora a variante disponibilizada no repositório seja denominada *Multi-Parent Biased Random-Key Genetic Algorithm with Implicit Path Relink* (BRKGA-MP-IPR), os parâmetros foram ajustados para refletir o BRKGA original, removendo as propriedades de multi-parentalidade e *Implicit Path-Relinking* (IPR). Para a implementação do Decoder, foi utilizada a linguagem de programação C++17. O RÓMULO foi executado em Python, versão 3.11.0, conforme o código original fornecido pelos autores [Jiménez et al., 2022].

A configuração da máquina utilizada para a execução dos experimentos consiste em um processador Intel Core i5-12400F de 12a geração, com 6 núcleos e frequência de 2,50 GHz, 32 GB de memória RAM DDR4 com frequência de 2,60 GHz, e uma placa de vídeo NVIDIA GeForce RTX 4060 com 8,0 GB de memória dedicada. O sistema operacional utilizado foi o Windows 11 Pro.

4.2. Configurações dos algoritmos

Para configurar o BRKGA, a ferramenta *irace* [López-Ibáñez et al., 2016] foi utilizada. Esses valores podem ser visualizados na Tabela 2. O RÓMULO foi configurado conforme as informações fornecidas em seu trabalho original.

4.3. Metodologia

Ambos os algoritmos foram executados com um tempo limite de cinco minutos para cada conjunto de dados, definido empiricamente, visando um equilíbrio entre qualidade das soluções e custo computacional. Apesar dessa restrição, os casos em que o limite de tempo foi excedido não foram descartados, com o objetivo de construir um conjunto de resultados mais robusto e contemplando o maior número possível de instâncias. Caso o algoritmo tenha interrompido o processa-

¹<https://github.com/ceandrade/brkga.mp-ipr-cpp>

Tabela 2: Parâmetros utilizados do BRKGA

Parâmetro	Valor
population_size	50
elite_percentage	0.16
mutants_percentage	0.27
num_elite_parents	1
total_parents	2
bias_type	CONSTANT
reset_interval	600
maximum_running_time	300
stall_offset	10

mento antes do tempo limite mas não tenha conseguido encontrar o melhor valor pra uma determinada instância, o tempo salvo para aquela instância será o tempo limite (300 segundos), para que as melhores soluções sejam priorizadas.

As métricas de avaliação utilizadas para mensurar a qualidade dos agrupamentos foram *Silhouette*, *Davies-Bouldin* e *Calinski-Harabasz*. A métrica *Silhouette* varia de $[-1.0, +1.0]$ e avalia o quão semelhantes os objetos são em relação ao seu próprio grupo quando comparados a outros grupos, considerando simultaneamente coesão e separação. O índice *Davies-Bouldin* varia de $[0.00, +\infty]$ e mede a razão entre a dispersão intra-grupo e a separação inter-grupos, sendo que valores menores indicam agrupamentos de melhor qualidade. Por fim, a métrica *Calinski-Harabasz* varia de $[0.00, +\infty]$ e avalia a razão entre a variância inter-grupos e a variância intra-grupos, favorecendo soluções com grupos bem separados e internamente compactos.

O RÓMULO é um algoritmo multi-objetivo, ou seja, sua função objetivo considera simultaneamente múltiplas métricas: *Silhouette*, *Davies-Bouldin*, *Calinski-Harabasz* e o número de grupos. Técnicas de otimização multi-objetivo enfrentam diversos desafios, especialmente relacionados à eficiência computacional, escalabilidade e precisão [Sharma e Kumar, 2022]. Esses desafios decorrem, em grande parte, da necessidade de otimizar simultaneamente múltiplos critérios, o que amplia a complexidade do espaço de busca em comparação a problemas mono-objetivo. Além disso, a presença de objetivos potencialmente conflitantes exige a obtenção de um conjunto de soluções *Pareto-ótimas*, ou seja, soluções nas quais nenhum objetivo pode ser melhorado sem que haja perda de desempenho em outro, refletindo diferentes *trade-offs* entre os critérios avaliados. Essas soluções podem não representar desempenhos satisfatórios em todos os critérios simultaneamente, especialmente em problemas de maior dimensionalidade. Em contraste, o BRKGA é um algoritmo mono-objetivo, sendo capaz de otimizar apenas uma métrica por vez, o que resulta em uma menor complexidade da solução e aumenta a eficiência computacional. Por outro lado, por retornar uma única solução ótima em vez de um conjunto de soluções Pareto-ótimas, o BRKGA não é capaz de capturar de forma explícita os *trade-offs* entre as métricas consideradas. Essa diferença estrutural entre os dois algoritmos torna a comparação direta pouco equilibrada, já que o RÓMULO precisa dividir seu esforço de otimização entre múltiplos critérios, enquanto o BRKGA concentra-se em um único.

Para mitigar esse efeito, além da comparação com a versão original (multiobjetivo) do RÓMULO, também foram consideradas versões mono-objetivo do algoritmo, nas quais apenas

uma métrica é otimizada por vez. Assim, cada configuração do BRKGA foi comparada com uma versão mono-objetivo do RÓMULO correspondente à mesma métrica, bem como com a versão original do método. Cabe destacar que a otimização do número de grupos foi mantida nas versões mono-objetivo do RÓMULO, uma vez que o método proposto também incorpora um viés que favorece soluções com menor quantidade de grupos.

4.4. Análise de agrupamento

A Tabela 3 apresenta as médias dos resultados obtidos para cada métrica de avaliação em cada *Data Lake*, bem como a média geral de cada métrica. Esses resultados podem ser melhor analisados através da Figura 2. A contabilização de vitórias, empates e derrotas está destacada na Figura 3.

Conj. de dados	<i>Silhouette</i>			<i>Davies-Bouldin</i>			<i>Calinski-Harabasz</i>		
	BRKGA	Ró-MO	Ró-MU	BRKGA	Ró-MO	Ró-MU	BRKGA	Ró-MO	Ró-MU
AFExp	0,7738	0,7814	0,8372	0,1377	0,1177	0,0877	241989,9444	5,900E+32	7,154E+32
ArtF	0,8380	0,6564	0,6586	0,2158	0,2866	0,2626	134943,0207	9,736E+32	2,434E+32
BrTax	0,9362	1,0000	1,0000	0,6633	0,0000	0,0000	339344,2807	9,253E+34	9,253E+34
COVID	0,9020	0,7868	0,8117	0,1117	0,2982	0,2803	1434,2651	82,4524	85,1463
Crime	0,9902	0,5790	0,5968	0,0100	0,3265	0,3084	283440,5489	81,6696	56,6011
Div	0,9262	0,7280	0,7593	0,0405	0,2010	0,1769	2,376E+14	4,690E+32	9,463E+32
EUFruit	0,9741	0,3447	0,3489	0,0320	0,4735	0,4964	26,3507	3,3340	3,2033
FarmOp	0,9988	0,6605	0,8147	0,0240	0,5188	0,2859	4,260E+14	7,315E+30	2,698E+31
GasEm	0,7400	0,7160	0,7413	0,1888	0,2019	0,1603	59384,0948	3075,7362	2774,7958
HikeT	0,9920	0,5828	0,4850	0,0024	0,3474	0,3679	5,7057	11,2602	7,6676
Marriage	0,8629	0,7369	0,8025	0,1206	0,2980	0,2149	1,813E+12	9,085E+10	9,085E+10
RockR	0,9033	0,8772	0,8996	0,3963	0,4080	0,3918	7,827E+08	14243,9339	15393,9765
SecLang	0,9060	0,9124	0,9258	0,0111	0,0870	0,0475	6,163E+15	3,764E+33	1,066E+33
TeenPreg	0,9918	0,8514	0,8941	0,0074	0,2268	0,0983	5,135E+12	9,585E+31	1,358E+32
Tuition	0,9987	0,6818	0,7011	0,0011	0,4323	0,3082	4,746E+09	1410,7195	4,146E+32
Uber	0,9468	0,2158	0,2969	0,0203	0,5180	0,5537	171,0678	3,1064	2,9194
WiFi	0,8151	0,8811	0,9055	0,2154	0,1051	0,0846	276863,3569	7,778E+32	1,556E+33
Média	0,9115	0,7054	0,7340	0,1293	0,2851	0,2427	4,020E+14	5,835E+33	5,743E+33

Tabela 3: Comparação entre BRKGA, RÓMULO mono-objetivo (MO) e multi-objetivo (MU). Os melhores valores por métrica estão destacados em negrito.




Figura 2: Gráfico boxplot das métricas (os losangos brancos representam a média).

Como pode ser observado através da Figura 2, o método proposto apresentou desempenho superior, superando o RÓMULO nas três métricas avaliadas. A abordagem obteve médias notáveis




Figura 3: Gráfico de barras dos resultados.

nas métricas *Silhouette* e *Davies-Bouldin*, com valores bem próximos de 1,0 e 0,0, respectivamente, além de uma maior estabilidade, com um menor desvio padrão em comparação ao RÓMULO. Os valores obtidos indicam a formação de agrupamentos bem estruturados, caracterizados por grupos compactos e bem separados, o que contribui para uma melhor interpretabilidade dos dados.

Para a métrica *Calinski-Harabasz*, o RÓMULO obteve médias extremamente altas em 9 dos 17 *Data Lakes* analisados (*AFExp*, *ArtF*, *BrTax*, *Div*, *FarmOp*, *SecLang*, *TeenPreg*, *Tuition* e *WiFi*), superando amplamente o BRKGA, como pode-se observar na Tabela 3. Porém, percebe-se, através das Figuras 2 e 3, que o BRKGA foi superior ao RÓMULO em mais instâncias. Isso demonstra que, apesar do potencial demonstrado pelo RÓMULO de atingir valores expressivos em instâncias específicas, o BRKGA apresentou resultados mais estáveis, superando o RÓMULO em cerca de 80% das instâncias.

4.5. Análise de eficiência (tempo de execução)

A Figura 4 apresenta os tempos de execução dos algoritmos analisados. Nota-se que o BRKGA apresentou menores médias, em especial para a métrica *Calinski-Harabasz*, que ficou abaixo dos 100s, enquanto o comportamento oposto é verificado para as duas versões do RÓMULO, que apresentaram uma concentração de resultados próximos ao tempo limite de 300 s. Esses resultados evidenciam a capacidade do método proposto de encontrar agrupamentos de qualidade de forma eficiente.




Figura 4: Gráfico do tempo de execução.

5. Conclusão

Este trabalho apresentou uma aplicação do BRKGA ao problema de agrupamento automático em *Data Lakes*. O objetivo do método proposto é auxiliar usuários na extração de informações relevantes a partir de seus dados, por meio da identificação de grupos compactos e bem

separados, capazes de evidenciar padrões ainda não descobertos nos dados analisados. O BRKGA foi confrontado com um método robusto de agrupamento automático em *Data Lakes* da literatura (RÓMULO), em termos de qualidade de agrupamento e eficiência computacional. Os experimentos foram realizados em 17 *Data Lakes*, e as métricas *Silhouette*, *Davies-Bouldin* e *Calinski-Harabasz* foram utilizadas para avaliar a qualidade do agrupamento. Nas métricas *Silhouette* e *Davies-Bouldin*, o BRKGA alcançou médias elevadas, com valores próximos dos limites ideais e menor desvio padrão, superando o RÓMULO em ambas, o que indica agrupamentos mais compactos, bem separados e estáveis. Para a métrica *Calinski-Harabasz*, embora o RÓMULO tenha atingido valores nominalmente superiores em 9 *Data Lakes*, o BRKGA mostrou-se mais consistente, superando o concorrente na maioria das instâncias. Quanto à eficiência computacional, o BRKGA obteve resultados superiores ao RÓMULO, registrando menores médias de tempo para as três métricas de avaliação consideradas.

Como trabalhos futuros, podem ser exploradas diferentes variantes do BRKGA, especialmente versões multiobjetivo, permitindo o uso simultâneo de múltiplas métricas de avaliação e, consequentemente, investigando soluções de forma mais ampla. Além disso, podem ser investigadas diferentes estratégias de codificação dos indivíduos, visando a uma exploração mais eficiente do espaço de busca e à otimização da quantidade de grupos selecionada. Por fim, meta-heurísticas voltadas para a organização de dados em *Data Lakes*, como a proposta por [Fernandes et al., 2024], podem ser exploradas como etapa prévia ao agrupamento, uma vez que dados previamente organizados podem potencialmente otimizar o processo de agrupamento dos dados.

Referências

- Alam, S., Dobbie, G., Koh, Y. S., Riddle, P., e Rehman, S. U. (2014). Research on particle swarm optimization based clustering: a systematic review of literature and techniques. *Swarm and Evolutionary Computation*, 17:1–13.
- Caliński, T. e Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics-theory and Methods*, 3(1):1–27.
- Davies, D. L. e Bouldin, D. W. (1979). A cluster separation measure. *IEEE transactions on pattern analysis and machine intelligence*, (2):224–227.
- Fernandes, D., Ramos, G. S., Pinheiro, R. G., e Aquino, A. L. (2024). A multi-start simulated annealing strategy for data lake organization problem. *Applied Soft Computing*, 160:111700.
- Gonçalves, J. F. e Resende, M. G. (2011). Biased random-key genetic algorithms for combinatorial optimization. *Journal of Heuristics*, 17(5):487–525.
- Greenlaw, R. e Kantabutra, S. (2013). Survey of clustering: algorithms and applications. *International Journal of Information Retrieval Research (IJIRR)*, 3(2):1–29.
- Hai, R., Koutras, C., Quix, C., e Jarke, M. (2023). Data lakes: A survey of functions and systems. *IEEE Transactions on Knowledge and Data Engineering*, 35(12):12571–12590.
- Ikotun, A. M., Almutari, M. S., e Ezugwu, A. E. (2021). K-means-based nature-inspired metaheuristic algorithms for automatic data clustering problems: Recent advances and future directions. *Applied Sciences*, 11(23):11246.
- Jain, A. K. (2010). Data clustering: 50 years beyond k-means. *Pattern recognition letters*, 31(8): 651–666.

- Jiménez, P., Roldán, J. C., e Corchuelo, R. (2022). On exploring data lakes by finding compact, isolated clusters. *Information Sciences*, 591:103–127.
- Kachaoui, J. e Belangour, A. (2019a). An adaptive control approach for performance of big data storage systems. In *International Conference on Advanced Intelligent Systems for Sustainable Development*, p. 89–97. Springer.
- Kachaoui, J. e Belangour, A. (2019b). A multi-criteria group decision making method for big data storage selection. In *International Conference on Networked Systems*, p. 381–386. Springer.
- Karim, M. R., Beyan, O., Zappa, A., Costa, I. G., Rebholz-Schuhmann, D., Cochez, M., e Decker, S. (2021). Deep learning-based clustering approaches for bioinformatics. *Briefings in bioinformatics*, 22(1):393–415.
- Lima, A., Lima, A., Nogueira, B., Santos, M., e Pinheiro, R. G. (2021). A multi-population brkga for the automatic clustering problem. In *2021 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, p. 368–373. IEEE.
- López-Ibáñez, M., Dubois-Lacoste, J., Cáceres, L. P., Birattari, M., e Stützle, T. (2016). The irace package: Iterated racing for automatic algorithm configuration. *Operations Research Perspectives*, 3:43–58.
- Min, E., Guo, X., Liu, Q., Zhang, G., Cui, J., e Long, J. (2018). A survey of clustering with deep learning: From the perspective of network architecture. *IEEE access*, 6:39501–39514.
- Nanda, S. J. e Panda, G. (2014). A survey on nature inspired metaheuristic algorithms for partitionial clustering. *Swarm and Evolutionary computation*, 16:1–18.
- Oyewole, G. J. e Thopil, G. A. (2023). Data clustering: application and trends. *Artificial intelligence review*, 56(7):6439–6475.
- Putrama, I. M. e Martinek, P. (2024). Heterogeneous data integration: Challenges and opportunities. *Data in Brief*, 56:110853.
- Rana, S., Jasola, S., e Kumar, R. (2011). A review on particle swarm optimization algorithms and their applications to data clustering. *Artificial Intelligence Review*, 35(3):211–222.
- Ren, Y., Pu, J., Yang, Z., Xu, J., Li, G., Pu, X., Yu, P. S., e He, L. (2024). Deep clustering: A comprehensive survey. *IEEE transactions on neural networks and learning systems*, 36(4): 5858–5878.
- Rodriguez, M. Z., Comin, C. H., Casanova, D., Bruno, O. M., Amancio, D. R., Costa, L. d. F., e Rodrigues, F. A. (2019). Clustering algorithms: A comparative approach. *PloS one*, 14(1): e0210236.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65. ISSN 0377-0427. URL <https://www.sciencedirect.com/science/article/pii/0377042787901257>.
- Sharma, S. e Kumar, V. (2022). A comprehensive review on multi-objective optimization techniques: Past, present and future. *Archives of Computational Methods in Engineering*, 29(7):5605–5633. ISSN 1886-1784. URL <https://doi.org/10.1007/s11831-022-09778-9>.